

Izluščitev podatkov iz HTML opisa

<https://gemini.google.com/app/ba8099cb38de459a>

User prompt: imam datoteko html in delam analizo teh podatkov vendar je problem saj je v html datoteki velikost leto izgradnje vse napisano pod description kako da razdelim to v svoji css datoteki da bo razdeljeno za kasnejšo analizo podatkov posiljam ti svojo trenutno kodo in kako je zapisano v html dokumentu teh dodatnih pojasnil npr mirna okolica ne potrebujem rabim le ceno velikost leto izgradnje

Response: Ker so podatki o velikosti, tipu, letu izgradnje in ostalih lastnostih zapisani kot enotno besedilo znotraj atributa itemprop="description" (npr. "127,9 m2, 3-sobno, zgrajeno l. 2027, 66 m2 zemljišča..."), jih lahko v vaši Python funkciji (BeautifulSoup) enostavno razčlenite z uporabo **redni izrazov (regularnih izrazov / re modula)**.

Ker ste omenili CSS datoteko – CSS (Cascading Style Sheets) služi izključno vizualnemu oblikovanju in stiliranju spletnih strani ter **nemore** izvajati logike ali razčlenjevati besedičnih podatkov za analizo. To se dela v Pythonu pri obdelavi podatkov (parsing).

Tukaj je popravljena in nadgrajena koda vaše funkcije, ki iz besedila avtomatsko potegne **velikost**, **leto izgradnje** in **ceno**, medtem ko odvečna besedila (kot so "mirna okolica" ipd.) preprosto ignorira.

Python koda za razčlenjevanje:

```
import re
from bs4 import BeautifulSoup

def get_dict_from_ad_block(block):
    """Iz posameznega bloka oglasa izlušči velikost, leto izgradnje in ceno

    ter zavrže nepotrebna besedila iz opisa.
    """
    soup = BeautifulSoup(block, 'html.parser')

    # 1. Pridobimo celoten opis po itemprop="description"
    desc_tag = soup.find(attrs={'itemprop': 'description'})
    opis = desc_tag.get_text(strip=True) if desc_tag else ''

    # 2. Pridobimo ceno iz oznake <h6> ali meta podatka
    h6_tag = soup.find('h6')
    if h6_tag:
        cena = h6_tag.get_text(strip=True)
    else:
        meta_tag = soup.find(attrs={'itemprop': 'price'})
        cena = meta_tag.get('content') if meta_tag else 'Ni podatka'

    if not opis and cena == 'Ni podatka':
        return None

    # --- EKSTRAKCIJA PODATKOV IZ OPISA Z REDNIMI IZRAZI (REGEX) ---

    # A) Velikost (išče vzorec številke z vejico ali piko, ki ji sledi m2, npr. "127,9 m2" ali "103,2 m2")
    velikost_match = re.search(r'([\d,\.\.]+)\s*m2', opis, re.IGNORECASE)
    velikost = velikost_match.group(1) if velikost_match else None

    # B) Leto izgradnje (išče "zgrajeno l. [leto]" ali "začetek gradnje l. [leto]" ali samo letnico po "l.")
    leto_match = re.search(
        r'(?:(?:zgrajeno|gradnje|l\.)\s*(\d{4})', opis, re.IGNORECASE
    )
    leto_izgradnje = leto_match.group(1) if leto_match else None

    # Lahko dodate še ekstrakt tipa stanovanja (npr. 3-sobno), če vam pride prav:
    tip_match = re.search(r'(\d+-sobno|novogradnja|penthouse)', opis, re.IGNORECASE)
    tip = tip_match.group(1) if tip_match else None

    return {
        'velikost_m2': velikost,
        'leto_izgradnje': leto_izgradnje,
        'tip': tip,
        'cena': cena,
    }
```

Kako to deluje:

1. `re.search(r'([\d,\.]+)\s*m2', opis)`: Poišče število (z vejico ali piko), ki stoji pred oznako m2, in ga shrani (npr. "127,9").
 2. `re.search(r'(?:(?:zgrajeno|gradnje|1\.)\s*[\.,]?s*(\d{4})', opis)`: Poišče štirimestno letnico (leto izgradnje ali začetek gradnje) ne glede na to, kako je točno zapisano v vrstici.
 3. Vsi ostali opisi (kot so lokacija, nadstropje, "mirno okolje" itd.) se enostavno ignorirajo, ker jih ne shranimo v slovar (return), s čimer dobite čiste podatke, pripravljene za analizo v Excelu ali Pandas DataFrameu.
-

User prompt: javlja mi to napako

Response: Pozabili ste uvoziti knjižnico za redne izraze na začetku datoteke.

Na sam vrh vaše datoteke `izlusci.py` (nad vsem ostalim kodam, zraven `from bs4 import BeautifulSoup`) preprosto dodajte:

```
import re
```

User prompt: to ze imam

Response: Če imate `import re` že vvožen na vrhu datoteke, je možen vzrok za to napako še to, da imate kodo morda v več datotekah (npr. `izlusci.py` in kakšni drugi skripti) in ste `import re` pozabili dodati ravno v to specifično datoteko ali pa je vnos na napačnem mestu.

Preverite, ali je `import re` res na samem začetku datoteke `izlusci.py` (tako nad definicijo funkcij ali uvozom `BeautifulSoup`).

Celotna uvodna vrstica na vrhu datoteke mora izgledati takole:

```
import re
from bs4 import BeautifulSoup
```

Če je to urejeno in napaka še vedno vztraja, preverite, da nimate kje v kodi spremenljivke z imenom `re` (npr. `re = 5`), ki bi povzila uvoz knjižnice.
