

Izračun korelacije in linearne regresije

<https://gemini.google.com/app/0c4575be037df530>

User prompt: ali obstaja kaj da racunsko pove povezavo neka vrednost koeficient itd

Response: Da, za matematično merjenje moči in smeri te povezave se uporablja **Pearsonov koeficient korelacije**, za iskanje dejanskega razmerja med spremenljivkama pa **koeficienti linearne regresije**.

Pearsonov koeficient korelacije (r)

- Meri moč linearne povezanosti in vedno zavzame vrednost med **-1 in 1**.
- **Pozitivna vrednost (blizu 1)**: Pomeni, da z večanjem velikosti sorazmerno raste tudi cena. Glede na razpršenost pik v datoteki image_137bcb.png bo ta vrednost močno pozitivna.
- **Vrednost okoli 0**: Pomeni, da med spremenljivkama ni opazne linearne povezave.
- **Negativna vrednost (blizu -1)**: Pomeni obratno sorazmerje.

Izračun korelacije v Pythonu:

```
import numpy as np
```

```
# Z uporabo knjižnice NumPy (vrne matriko, zato vzamemo element [0, 1])
korelacija = np.corrcoef(velikosti, cene)[0, 1]
print(f"Korelacijski koeficient: {korelacija:.2f}")
```

```
# Alternativa: Če so vaši podatki v Pandas DataFrame obliki (npr. 'df')
# korelacija = df['velikosti'].corr(df['cene'])
```

Linearna regresija (enačba premice) Če želite izračunati koeficient, ki vam pove točno to, **za koliko evrov v povprečju zraste cena ob vsakem dodatnem kvadratnem metru**, morate izračunati naklon premice (k) po formuli $y = kx + n$.

Izračun regresijskih koeficientov v Pythonu:

```
# Funkcija polyfit (stopnje 1) poišče premico, ki se najbolje prilega vašim pikam,
# in vrne naklon (k) ter presečišče z osjo y (n).
k, n = np.polyfit(velikosti, cene, 1)
```

```
print(f"Za vsak dodaten m2 se cena v povprečju dvigne za {k:.2f} €.")
print(f"Matematični model: Cena = {k:.2f} * Velikost + {n:.2f}")
```

Z uporabo funkcije `plt.plot(velikosti, k * np.array(velikosti) + n, color='blue')` bi nato lahko to izračunano premico trenda narisali neposredno čez vaš obstoječi graf.

User prompt: razloži mi to kodo `import numpy as np` # Z uporabo knjižnice NumPy (vrne matriko, zato vzamemo element [0, 1]) `korelacija = np.corrcoef(velikosti, cene)[0, 1]` `print(f"Korelacijski koeficient: {korelacija:.2f}")`

Response: Spodaj je razlaga posameznih delov kode:

- `import numpy as np` Uvozi knjižnico **NumPy**, ki je v Pythonu zlati standard za delo z numeričnimi podatki in matrikami. Okrajšava `as np` pomeni, da bomo v nadaljevanju kode knjižnico klicali s krajšim imenom `np`.

- `np.corrcoef(velikosti, cene)` Ta funkcija izračuna linearno povezanost (Pearsonov koeficient korelacije) med vašima seznamoma `velikosti` in `cene`. Ker zna NumPy računati korelacije med več spremenljivkami hkrati, kot rezultat **ne vrne le enega števila, temveč matriko (tabelo) velikosti 2x2**.
 - `[0, 1]` Ker je rezultat matrika 2x2, moramo iz nje izluščiti točno tisto vrednost, ki jo potrebujemo.
 - V matriki sta na diagonalni korelacija spremenljivke same s seboj (vrednost 1.0).
 - Izven diagonale (v 0. vrstici in 1. stolpcu oz. `[0, 1]`) pa se nahaja iskani koeficient korelacije med velikostjo in ceno nepremičnin.
 - `print(f"Korelacijski koeficient: {korelacija:.2f}")` Izpiše končni rezultat na zaslon. Uporablja t. i. *f-string* za lepše oblikovanje izpisa, zapis `:.2f` pa poskrbi, da se izračunano število zaokroži na dve decimali natančno (npr. 0.85).
-

User prompt: in kaj nam pove ta

Response: Vrednost, ki jo dobiš kot rezultat (število med -1 in 1), ti pove **kako močna in v katero smer je linearna povezava** med velikostjo nepremičnine in njeno ceno.

Interpretacija končne številke poteka takole:

- **Vrednost med 0.7 in 1.0 (ali -0.7 in -1.0): Močna povezava** Pomeni, da so podatki tesno povezani. V tvojem primeru (če je vrednost npr. 0.8) to pomeni, da velikost zelo močno določa ceno – večja ko je nepremičnina, skoraj zagotovo višja je cena.
- **Vrednost med 0.3 in 0.7 (ali -0.3 in -0.7): Zmerna povezava** Povezava obstaja, vendar obstaja tudi precej "šuma" oziroma odstopanj. Točno to se vidi na tvojem grafu: čeprav je splošni trend naraščajoč, imaš primere, kjer je manjša nepremičnina dražja od precej večje (verjetno zaradi lokacije, stanja ali opreme).
- **Vrednost blizu 0 (med -0.3 in 0.3): Ni povezave** Pomeni, da na podlagi velikosti sploh ne moreš predvidevati cene, ker sta spremenljivki povsem neodvisni.

Glede na tvoj graf bo izračunana korelacija verjetno nekje v območju **0.6 do 0.8**, kar potrjuje, da velikost in cena močno, a ne stodstotno sorazmerno sovpadata.
